

# Olasılıksal Robotik

Dr. Öğr. Üyesi Erkan Uslu

# Parametrik Olmayan Filtreler

- Kalman ve türevleri parametrik ve fonksiyonel olarak tanımlanabilir posterior olasılık dağılımı (gauss dağılımı) varsayımına sahiptir
- Parametrik olmayan filtreler ise posterior olasılık dağılımını sonlu sayıda değer ile temsil eder
  - Durum uzayını ayrıştırarak → Histogram filtresi
  - Rastgele örnek üreterek → Parçacık filtresi
- Parametrik olmayan filtreler kompleks multimodal dağılımları temsil edebilir.

# Parametrik Olmayan Filtreler

- Parametrik olmayan filtrelerin temsil kabiliyeti parametre sayısı ile doğru orantılıdır
- Posterior olasılık düşük bir karmaşıklığa sahipse (durum uzayı bir durum çevresinde odaklı ve düşük belirsizliğe sahipse) parametre sayısı az olur
- Kompleks posterior olasılıklar için ise parametre sayısı yüksek olur

# Histogram Filtresi

- Durum uzayı sonlu sayıda bölgeye ayrıştırılır
- Durum uzayının yapısına göre
  - Sürekli durum uzayı → Histogram filtresi
  - Sonlu durum uzayı → Discrete Bayes filtresi

# Discrete Bayes Filtresi

---

**Algorithm 1:** Ayırık (Discrete) Bayes Filtresi

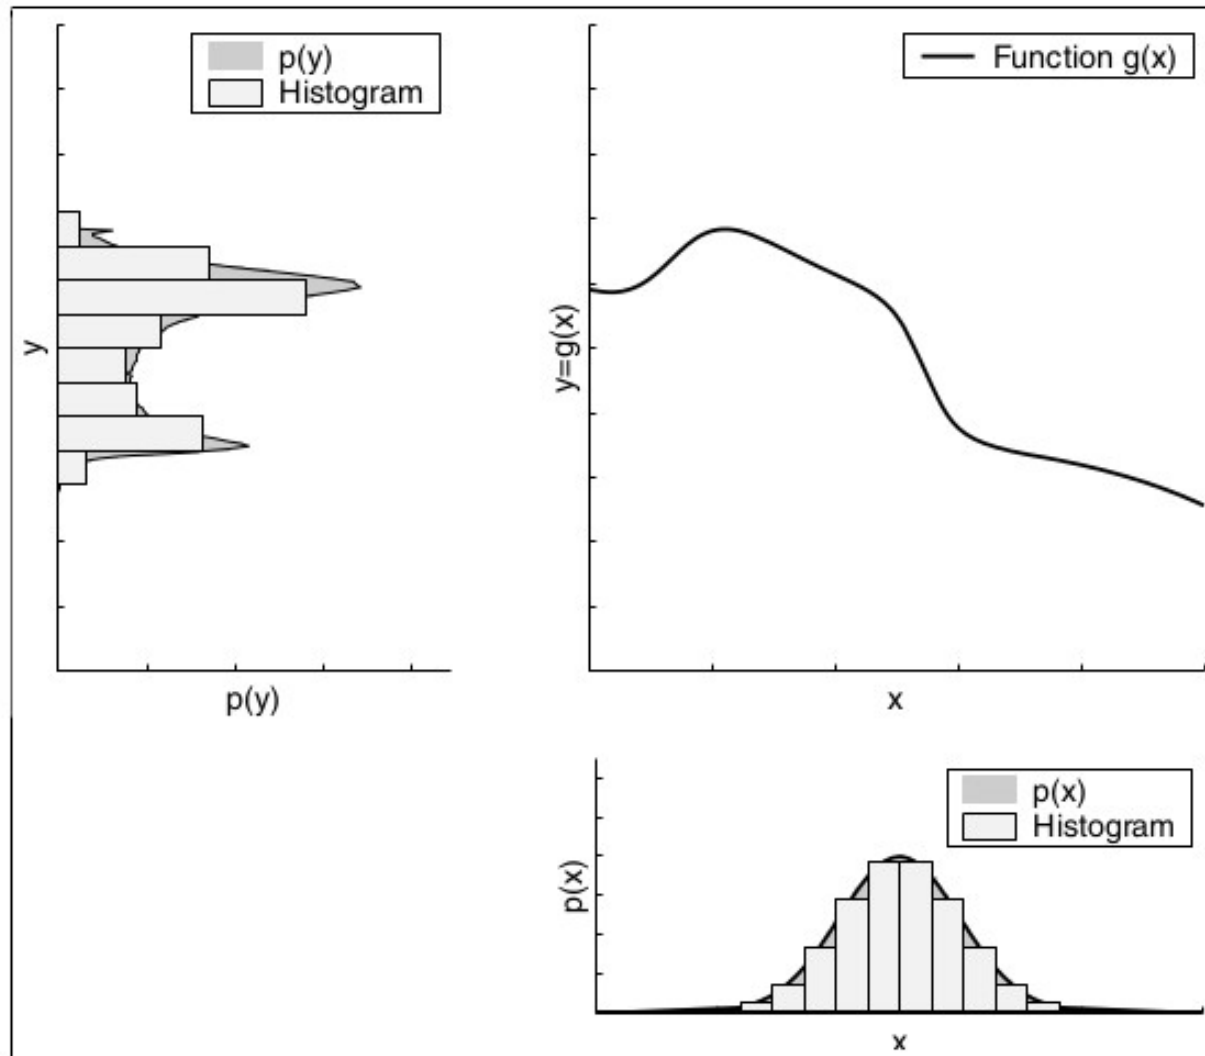
---

**input** :  $p_{k,t-1}, u_t, z_t$   
**output:**  $p_{k,t}$

- 1 **forall**  $k$  **do**
- 2      $\bar{p}_{k,t} = \sum_i p(X_t = x_k | X_{t-1} = x_i, u_t) p_{i,t-1};$
- 3      $p_{k,t} = \eta p(z_t | X_t = x_t) \bar{p}_{k,t};$
- 4 **end**



---

# Histogram Filtresi



# Histogram Filtresi

- Ayırıştırma yöntemleri
- Statik ayırıştırma:
  - 1B uzay için eşit aralık binler
  - 2B uzay için eşit aralık ızgaralar (grids)
- Dinamik ayırıştırma:
  - Yoğunluk ağaçları (density trees)
- Hibrid ayırıştırma:
  - Seçici güncelleme (selective updating)

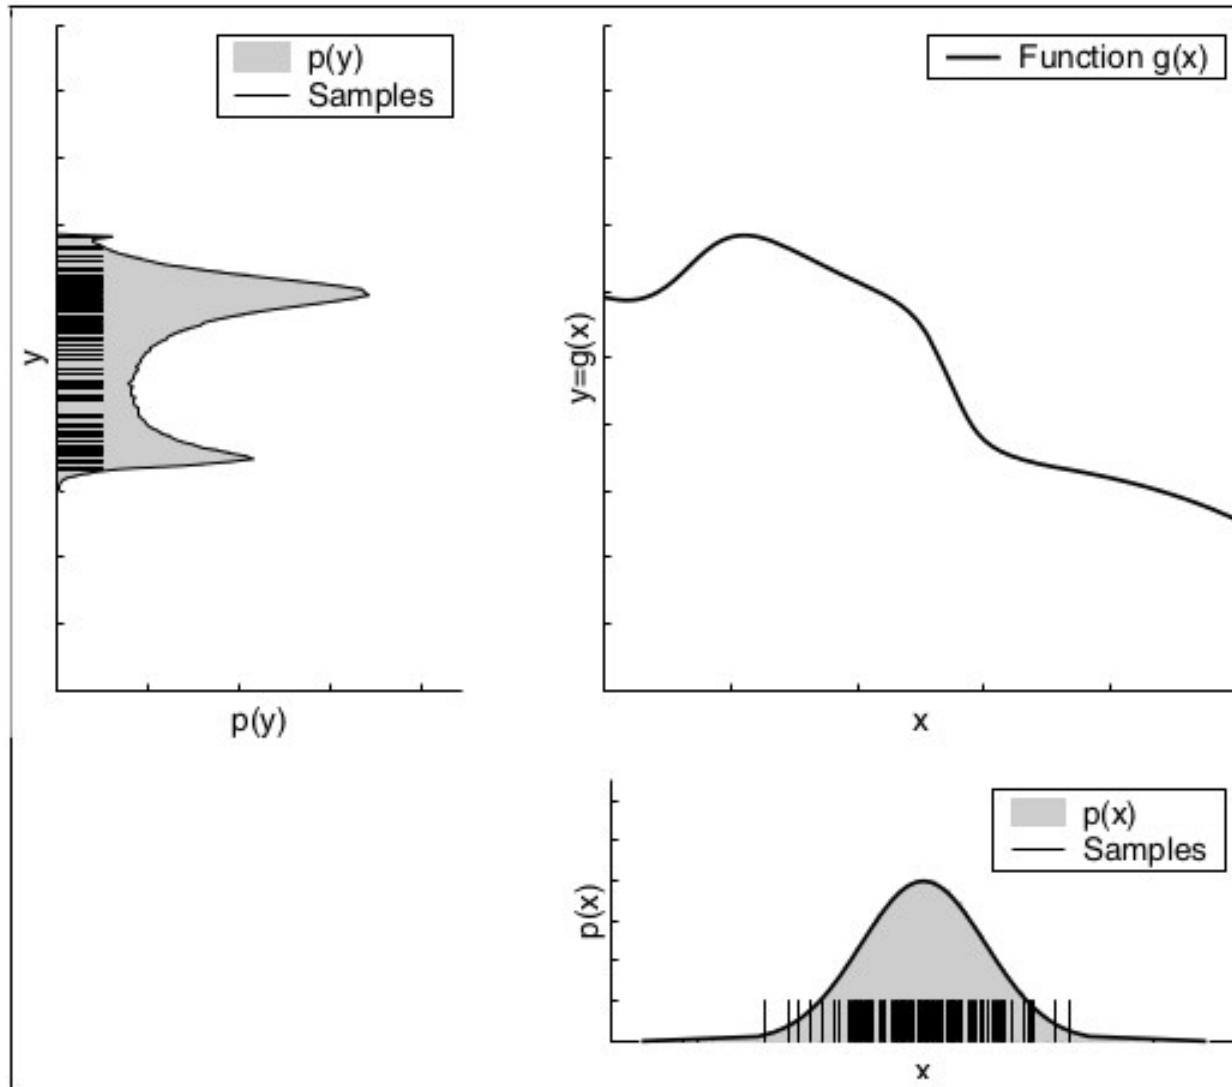


# Parçacık Filtresi – Particle Filter

- Posterior olasılık rastgele (random) olarak üretilmiş örnekler ile temsil edilir
- Karmaşık olasılık dağılımları temsil edilebilir
- Random değişkenlerin doğrusal olmayan dönüşümlerinde de iyi temsil kabiliyetine sahiptir



# Parçacık Filtresi – Particle Filter



# Parçacık Filtresi – Particle Filter

---

## Algorithm 1: Parçacık (Particle) Filtresi

---

**input** :  $\chi_{t-1}, u_t, z_t$   
**output**:  $\chi_t$

- 1  $\bar{\chi}_t = \chi_t = \emptyset;$
- 2 **for**  $m \leftarrow 1$  **to**  $M$  **do**
- 3     *sample*  $x_t^{[m]} \sim p(x_t | u_t, x_{t-1}^{[m]});$
- 4      $w_t^{[m]} = p(z_t | x_t^{[m]});$
- 5      $\bar{\chi}_t = \bar{\chi}_t \cup \langle x_t^{[m]}, w_t^{[m]} \rangle;$
- 6 **end**
- 7 **for**  $m \leftarrow 1$  **to**  $M$  **do**
- 8     *sample*  $x_t^{[i]} \sim w_t^{[i]};$
- 9      $\chi_t = \chi_t \cup x_t^{[i]};$
- 10 **end**

---

# Parçacık Filtresi – Particle Filter

---

## Algorithm 1: Parçacık (Particle) Filtresi

---

**input** :  $\chi_{t-1}, u_t, z_t$

**output**:  $\chi_t$

1  $\bar{\chi}_t = \chi_t = \emptyset$ ;

2 **for**  $m \leftarrow 1$  **to**  $M$  **do**

3     *sample*  $x_t^{[m]} \sim p(x_t | u_t, x_{t-1}^{[m]})$ ;

4      $w_t^{[m]} = p(z_t | x_t^{[m]})$  ;

5      $\bar{\chi}_t = \bar{\chi}_t \cup \langle x_t^{[m]}, w_t^{[m]} \rangle$ ;

6 **end**

7 **for**  $m \leftarrow 1$  **to**  $M$  **do**

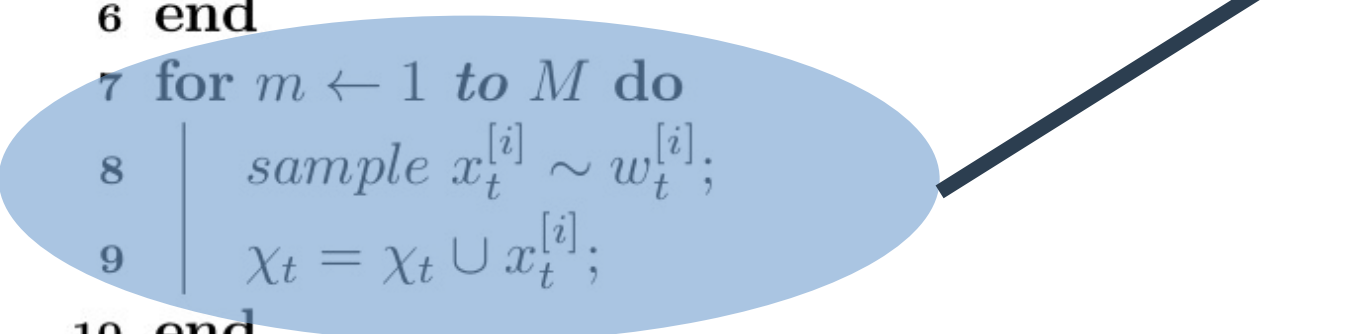
8     *sample*  $x_t^{[i]} \sim w_t^{[i]}$ ;

9      $\chi_t = \chi_t \cup x_t^{[i]}$ ;

10 **end**

---

Resampling  
Importance sampling




# Resampling – Importance Sampling

$$\begin{aligned} E_f [x] &= \int f(x) x dx \\ &= \int \frac{f(x)}{g(x)} g(x) x dx \\ &= \int \omega(x) g(x) x dx \\ &= E_g [\omega(x) x] \end{aligned}$$


# Resampling – Importance Sampling

- Elde etmek istenen temsil




# Resampling – Importance Sampling

- Mevcut örnekler



# Resampling – Importance Sampling

- Elde edilmek istenen temsile göre ağırlıklandırma




# Ters Dönüşüm ile Örneklem

- P 1B olasılık dağılımına ilişkin PDF üzerinden integral alınarak CDF elde edilir
- Uniform dağılıma uygun bir  $x$  random sayısı üretilir
- $CDF^{-1}(x)$  P olasılık dağılımına göre üretilmiş bir random örnek olarak elde edilir



# Ters Dönüşüm ile Örneklem (PDF)


- $p(a)=$   
[0.028, 0.056,  
0.110, 0.083,  
0.042, 0.014,  
0.014, 0.014,  
0.028, 0.069,  
0.125, 0.139,  
0.125, 0.083,  
0.056, 0.014]



# Ters Dönüşüm ile Örnekleme (CDF)

- $p(a)=$

[0.028, 0.056,  
0.110, 0.083,  
0.042, 0.014,  
0.014, 0.014,  
0.028, 0.069,  
0.125, 0.139,  
0.125, 0.083,  
0.056, 0.014]



# Ters Dönüşüm ile Örneklem

```
a=[0.028, 0.056, 0.110, 0.083, 0.042, 0.014, 0.014, 0.014, 0.028, 0.069, 0.125, 0.139,  
0.125, 0.083, 0.056, 0.014];
```

```
bar(a);
```

```
b(1)=a(1);
```

```
for i=2:16
```

```
    b(i)=b(i-1)+a(i);
```

```
endfor
```

```
figure
```

```
bar(b)
```

# Ters Dönüşüm ile Örneklem

```
for i=1:100  
    c(i)=rand;  
endfor
```


```
for i=1:100  
    j=1;  
    while(c(i)>b(j) && j<=16)  
        j=j+1;  
    endwhile  
    s(i)=j;  
endfor
```

# Ters Dönüşüm ile Örneklem



```
for i=1:16  
    bin(i)=sum(s==i);  
endfor  
  
figure  
bar(bin)
```

# Ters Dönüşüm ile Örnekleme

# of samples



# Gerçek Dağılım – Üretilen Örnekler




# Rejection Sampling

- Bilinen bir  $Q$  dağılımı kullanarak  $P$  dağılımı için örnekleme yapılmak istenirse
- $c$  bir sabit olmak üzere  $cQ \geq P$  olacak şekilde üstten limitleyen bir dağılım kullanılır
- $Q$ 'dan bir  $x$  örnekleme yapılır
- $[0, cQ]$  aralığından  $u$  uniform bir örnek üretilir
- $u \leq P(x)$  ise örnekleme kabul edilir değilse reddedilir



# Rejection Sampling



# Normal Dağılım için Örnekleme – Box Muller Metodu

$$u_1, u_2 \sim Unif(0, 1)$$

$$R = \sqrt{-2 \log(u_1)}$$

$$\theta = 2\pi u_2$$

$$(x, y) = (R \cos \theta, R \sin \theta)$$

# Normal Dağılım için Örneklememe – Central Limit Theorem


- Central Limit Theorem : bağımsız rassal değişkenler toplandığında bunların normalize edilmiş toplamaları normal dağılımı yakınsar
- Probabilistic robotics:  $b^2$  varyanslı, 0 ortalamalı normal dağılımdan örneklememe için

$$\frac{1}{2} \cdot \sum_{i=1}^{12} rand(-b, b)$$

# Üçgen Dağılım Örneklemesi

- Üçgen dağılım normal dağılımın basitleştirilmiş bir versiyonu olarak düşünülebilir
- Probabilistic robotics:  $b^2$  varyanslı, 0 ortalamalı üçgen dağılımdan örneklemesi için

$$\frac{\sqrt{6}}{2} \cdot [rand(-b, b) + rand(-b, b)]$$



# Örnek

- Mobil robot 2B uzayda sadece belirli bir doğrultuda uygulanan kontrol işareti  $L$  kadar hareket edebilmektedir. Robot bulunduğu konumun  $x$  eksenine izdüşümünü normal dağılıma uygun bir hata terimi ile ölçebilmektedir.
- Robota ilişkin durum tanımı aşağıda verilmiştir.

$$\mathbf{x} = \begin{pmatrix} x \\ y \\ \theta \end{pmatrix} \quad \begin{pmatrix} x' \\ y' \\ \theta' \end{pmatrix} = \begin{pmatrix} x + L \cos \theta \\ y + L \sin \theta \\ \theta \end{pmatrix} \quad \mathbf{z} = \mathbf{x}'$$



# Örnek

- Robotun başlangıç durum inancı aşağıdaki gibidir



$$\mu_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \quad \Sigma_0 = \begin{pmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 10000 \end{pmatrix}$$

- Başlangıç durumuna göre 1000 adet parçacığın dağılımını sağlayın
- Robotun L=2 birim ilerleme komutunu yürütmesi sonrası parçacıkların dağılımını sağlayın
- Robotun z=1.5 birim ölçüm alması sonucu parçacık dağılımını sağlayın

# Örnek – Başlangıç konumu için parçacıklar




# Örnek – L=2 ile hareket sonucu parçacıklar





# Örnek – $z=1.5$ için parçacık ağırlıkları



# Örnek – Resampling sonucu parçacıklar

