KELİME GÖSTERİLİMLERİ

(Word Representation – Word Embeddings)

Prof. Dr. Banu DİRİ

➢Kelime, cümlede kullanımına göre farklı anlamlar kazanabilir

➢ Anlamsal bilginin çıkarılması metinlerin işlenmesinde önemlidir

➢ Kelimelerin işlenebilir formattaki haline **Kelime Gösterilimi** denir

Kelime gösterilimi :

❖Frekans Tabanlı Kelime Gösterilimi (*Count Vector, Tf-Idf*)

❖Tahminleme Tabanlı Kelime Gösterilimi (*Word2Vec, GloVe*

– *Derin Öğrenme Yaklaşımlı Yapay Sinir Ağı Yöntemleri)*

Bilimin değeri işleri karmaşık hale getirmek değil, özündeki basitliği bulmaktır.
Frank Seide

Doğal Dil İşlemede kelimeleri bilgisayarların anlayabilmesi için sayısal değerler haline getiririz.

Vektör Uzay Modelleri (Vector Space Models) bir öğeyi-item (ör:kelime) sayı vektörü olarak gösterir.

banana

❖Tahminleme yaklaşımları ile kelimeler arasındaki anlamsal ilişkiler çıkarılabilir

Erkek →Kadın | Kral → ? (Kraliçe)

❖Kelime vektörleri arasındaki mesafe (*Cosine Similarity*)

❖Kelime Vektörlerinin öğrenilmesi eğiticisiz öğrenmeye girer

❖Her kelime için belirli sayıda özellik öğrenilir

❖Her özellik bir anlamsal bilgi taşır

1- One-hot Gösterimi

One-hot encoding, kelimeleri tanımlamak için kullanılan yöntemlerden biridir.

Vektörün boyu elimizdeki kelimelerin çeşitliliği kadardır.

Vektörde sadece ilgili kelimenin bulunduğu yerin değeri 1,

diğer tüm kelimelerin değeri 0’dır.

a	adam		zebra	Zil
1	0		0	0
0	1		0	0
0	0		0	0
. . .	. . .	.....	. . .	. . .
0	0		1	0
0	0		0	1

2 - Vektör, kelimenin geçtiği dokümanlara karşılık gelebilir.

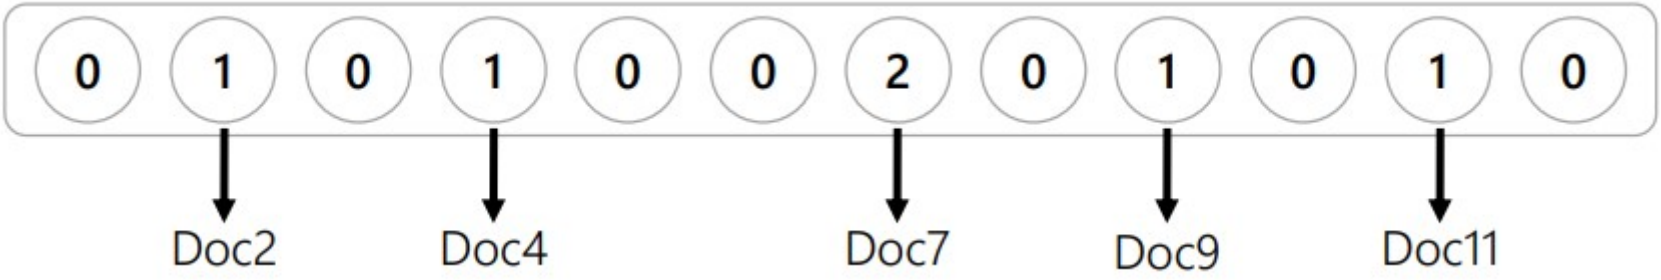

3 - Vektör, komşu kelime bağlamına karşılık gelebilir.

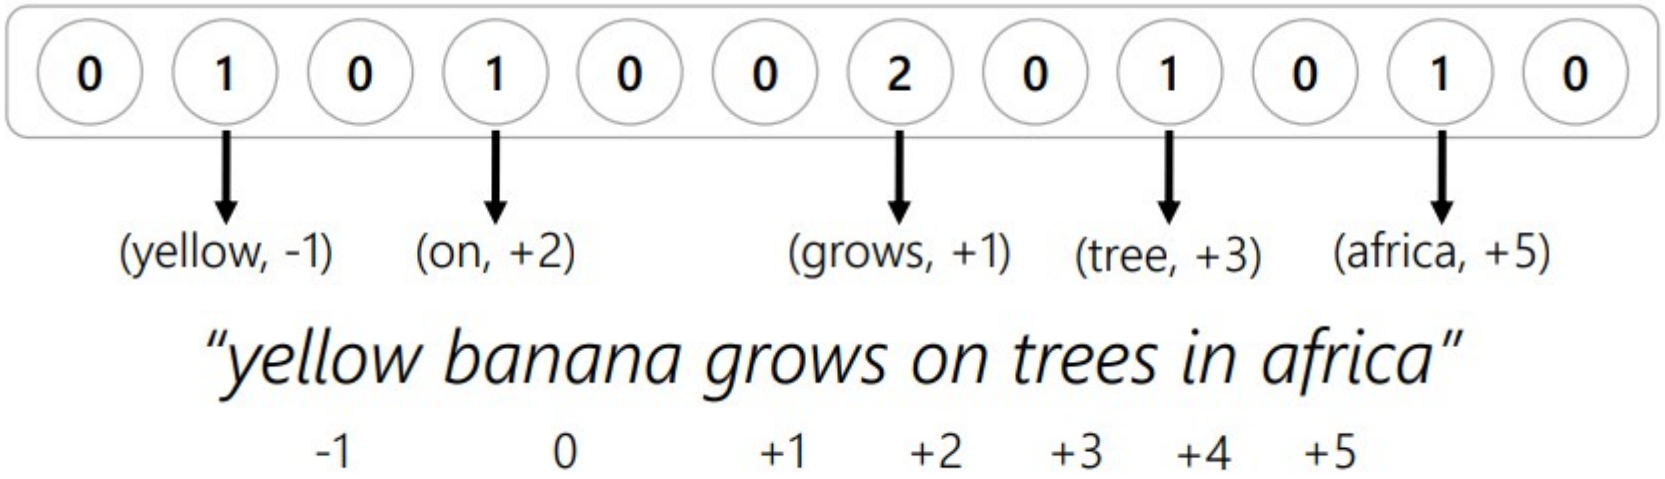

4 - Vektör, kelimedeki karakter trigramlarına karşılık gelebilir.

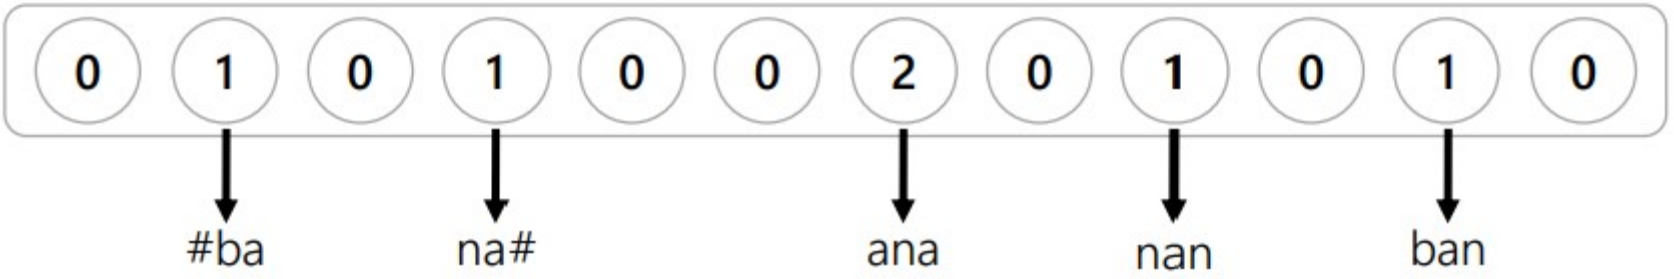

İlgililik- Relatedness Kavramları

İki vektörün karşılaştırılması (örneğin, kosinüs benzerliği), iki kelimenin ne kadar benzer olduğunu tahmin eder.

Bununla birlikte, ilgililik kavramı, kelimeler için hangi vektör gösterimini seçtiğinize bağlıdır.

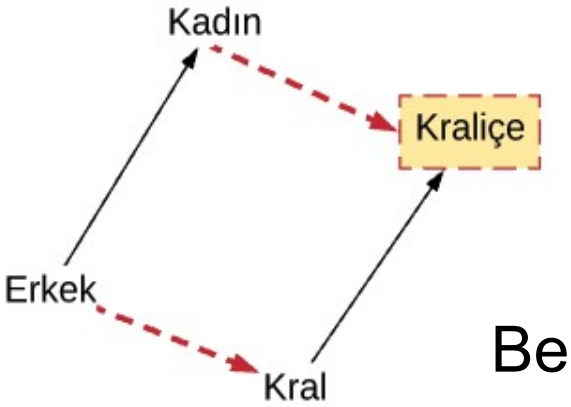

Benzerlik Hesabı Sonucu Bulunan Kelime

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|_2 \|\mathbf{B}\|_2} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \sqrt{\sum_{i=1}^{n} B_i^2}} \qquad (6)$$

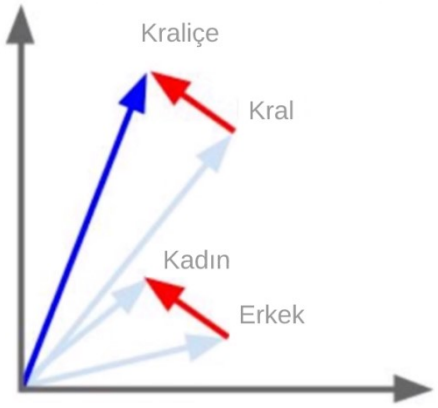

Cosine Similarity ile Anlamsal Bilginin Çıkarılması

seattle similar to denver?
Because they are both cities.

veya

seattle similar to seahawks?
Because “Seattle Seahawks”.

Dört tane dokümanımız olsun

Doküman 1 : “seattle seahawks jerseys”
Doküman 2 : “seattle seahawks highlights”
Doküman 3 : “denver broncos jerseys”
Doküman 4 : “denver broncos highlights”

Kelimelerin dokümanda geçip geçmediği bilgisini kullanırsak...

Topical similarity

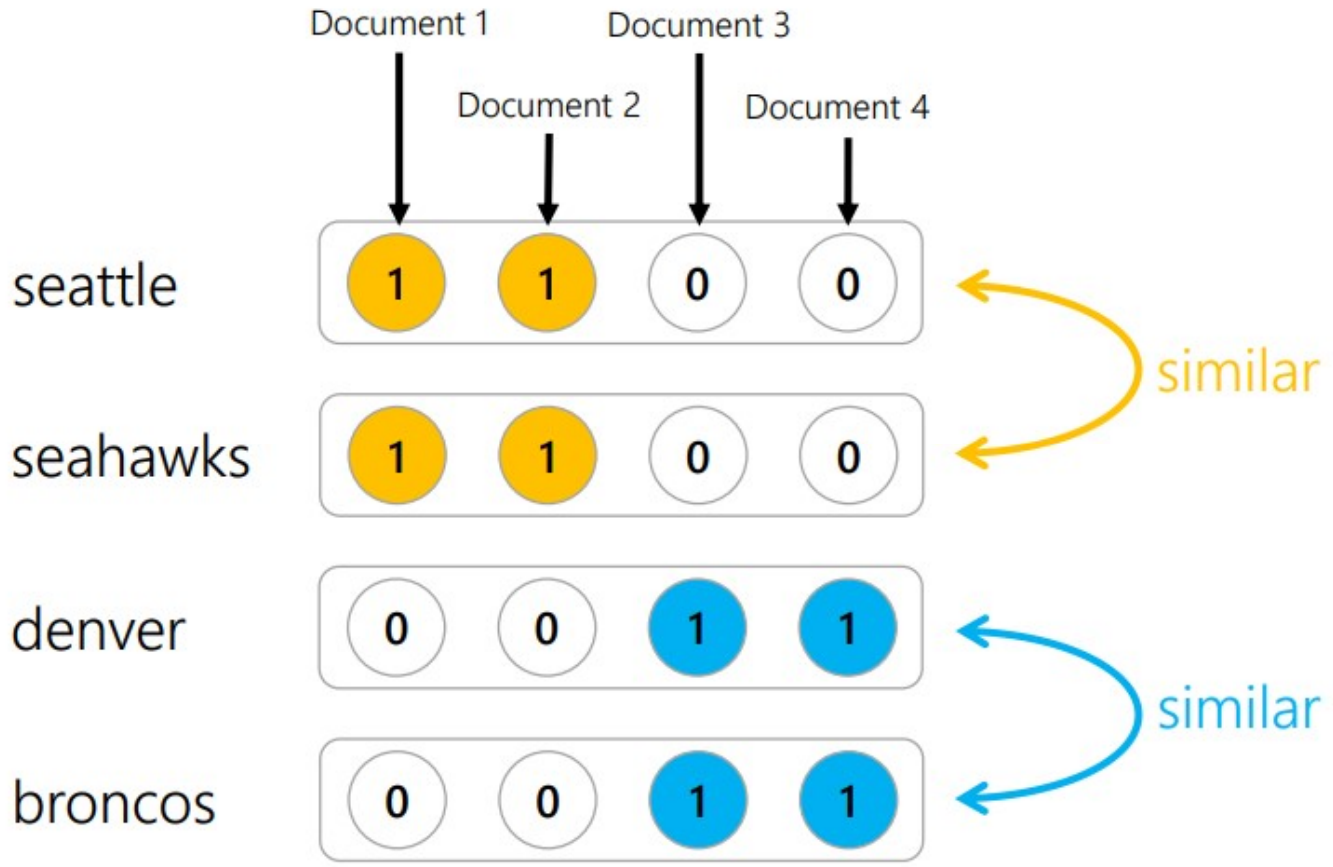

Eğer bağlam vektörlerini kullanırsak… *(Typical (by-type))*

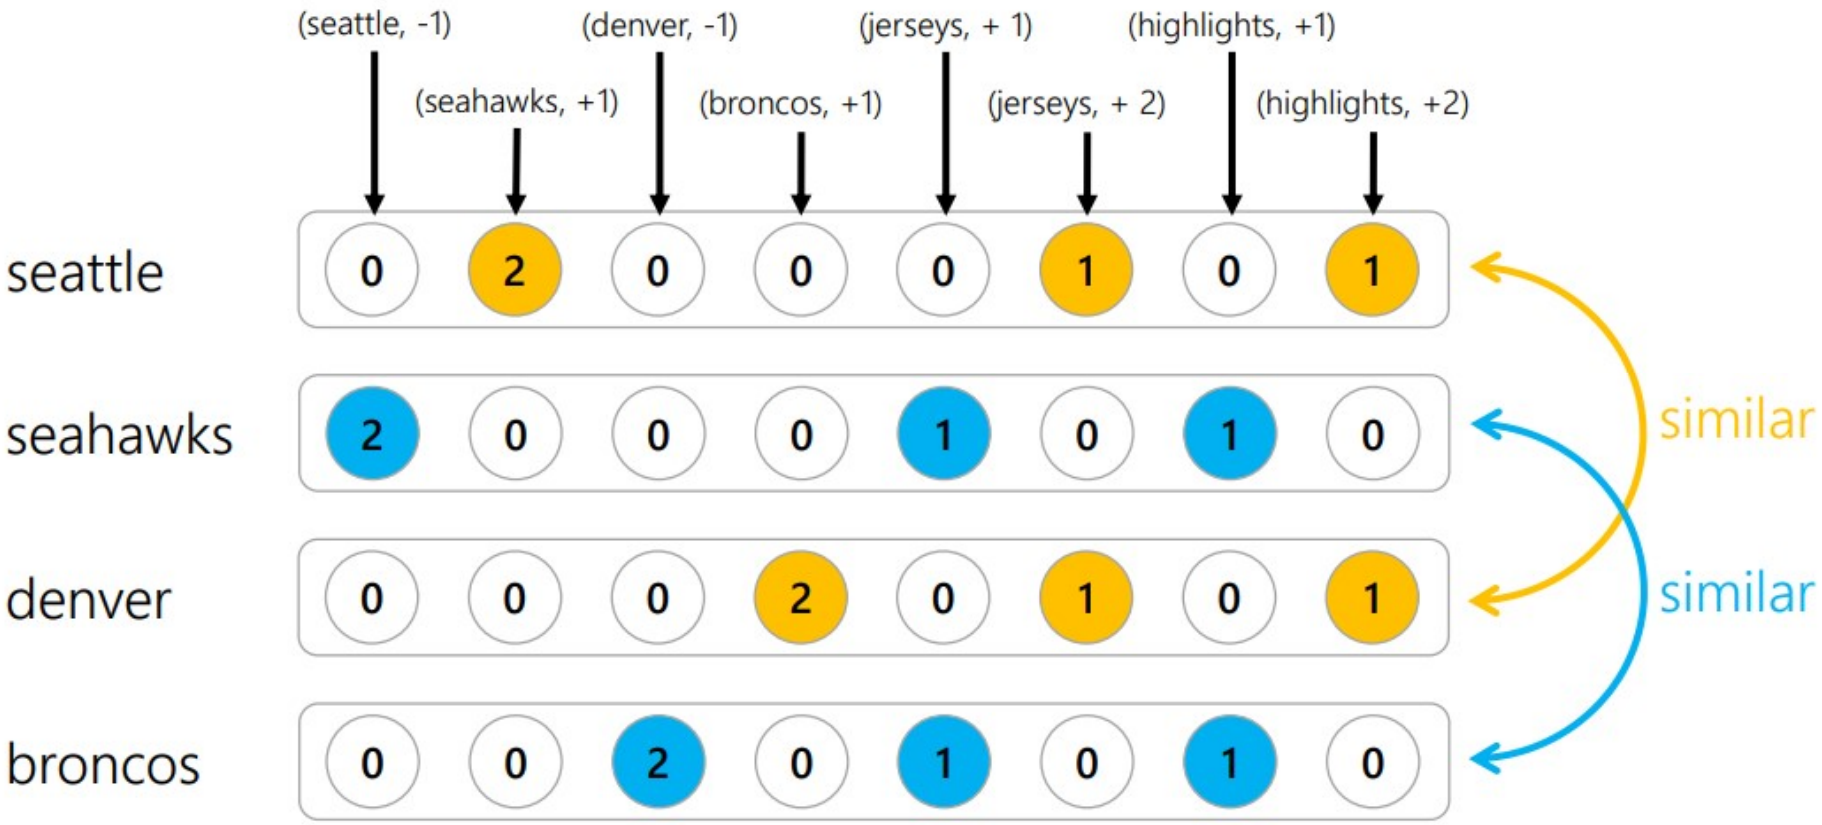

Eğer karakter 3-grams vektörlerini kullanırsak…

edit-distance

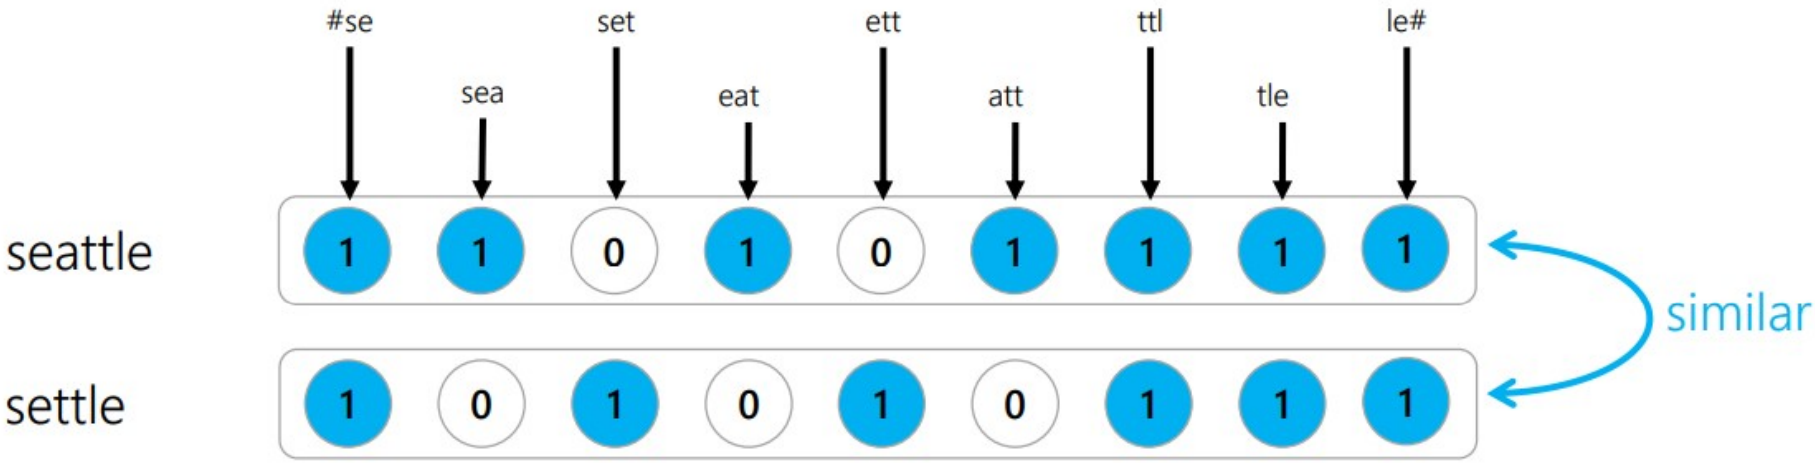

Her word-contex çiftini Pointwise Mutual Information ile ölçelim.

$$\mathrm{pmi}(x;y) \equiv \log \frac{p(x,y)}{p(x)p(y)}$$

Enter a word sydney Lookup

Words	Similarity Coefficient
sydney	1
melbourne	0.4376428
brisbane	0.4071144
perth	0.3362517
adelaide	0.2916113
auckland	0.2493333

Enter a word batman Lookup

Words	Similarity Coefficient
batman	1
spiderman	0.1429663
superman	0.137329
ghostbusters	0.1045547
tinkerbell	0.08972809
starwars	0.07744732

Her word-contex çiftini Cosine Similarity ile ölçelim.

$$\vec{a} \cdot \vec{b} = \|\vec{a}\| \|\vec{b}\| \cos\theta$$

$$\cos\theta = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \|\vec{b}\|}$$

Enter a word java Lookup

Words	Similarity Coefficient
java	1
c	0.1601557
javascript	0.145963
powershell	0.1096152
python	0.09570167
vb	0.0907691

Enter a word pasta Lookup

Words	Similarity Coefficient
pasta	1
spaghetti	0.1822345
lasagna	0.1541065
macaroni	0.1090949
salad	0.1030677
casserole	0.09800283

Kelime benzerliği-analojisi

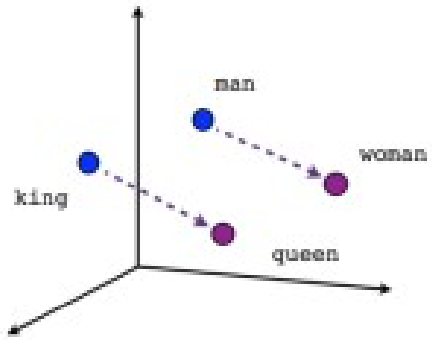

Male-Female

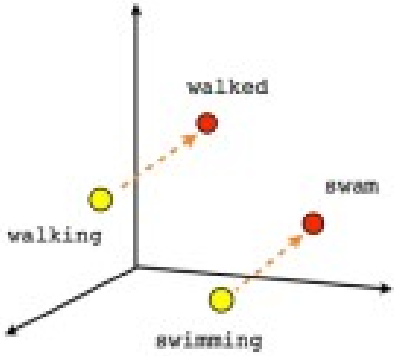

Verb tense

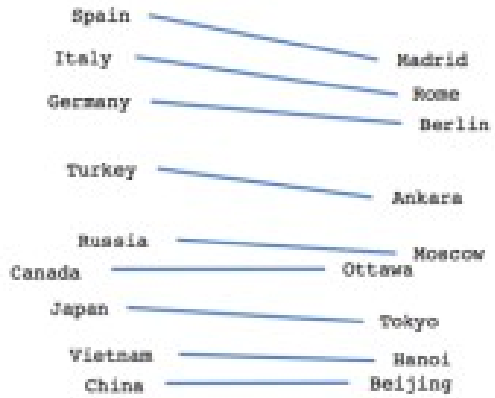

Country-Capital

man is to woman as king is to ?

good is to best as smart is to ?

china is to beijing as russia is to ?

word-context kelime modeli kelime analojisi için iyi bir çözümdür.

[king] – [man] + [woman] ≈ [queen]

Kelime Gömmeleri-Word Embeddings

Şimdiye kadar görmüş olduğumuz vektörler çok yüksek boyutlu (binlerce) ve seyrekti (sparse).

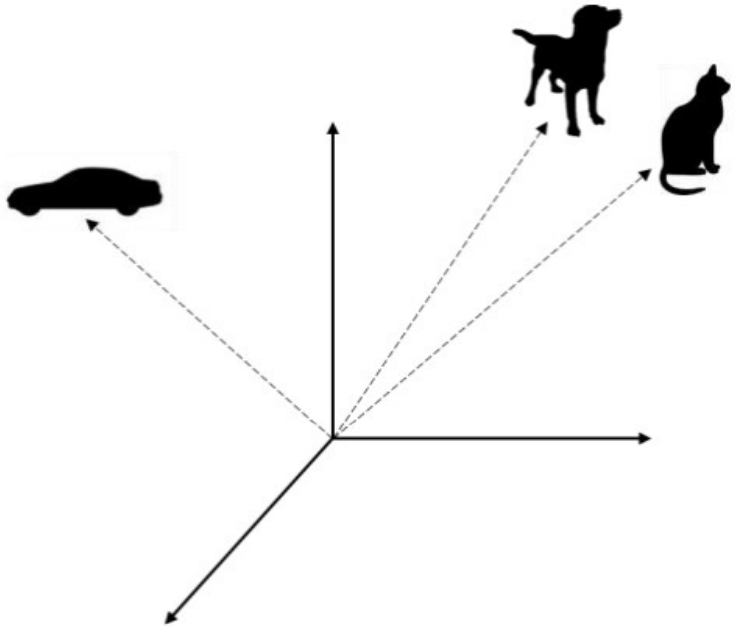

Ancak, aynı sezgileri kullanan kelimeler için düşük boyutlu yoğun vektörleri öğrenme teknikleri de vardır.
Bu yoğun vektörlere **gömme-embedding** denir.

Word Embedding benzer anlamdaki kelimelerin yakın şekilde temsil edilmesine yarayan bir yöntemdir. Google'da çalışan Tomas Mikolov ve ekibi tarafından 2013 yılında geliştirilmiştir.

Matrix Factorization

Factorize word-context matrix.

	$Context_1$	$Context_1$	....	Context $_k$
$Word_1$				
$Word_2$				
⋮				
$Word_n$				

E.g.,

LDA (Word-Document),

GloVe (Word-NeighboringWord)

Deerwester, Dumais, Landauer, Furnas, and Harshman, Indexing by latent semantic analysis, JASIS, 1990. Pennington, Socher, and Manning, GloVe: Global Vectors for Word Representation, EMNLP, 2014.

Neural Networks

A neural network with a bottleneck, word and context as input and output respectively.

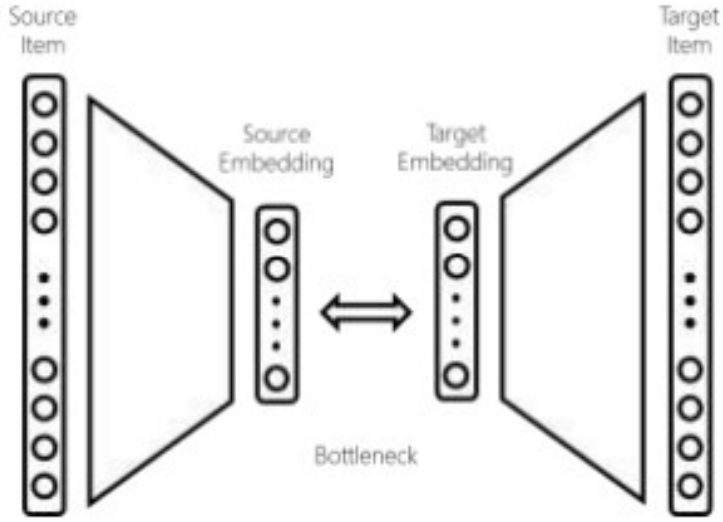

E.g.,

Word2vec (Word-NeighboringWord)

Mikolov, Sutskever, Chen, Corrado, and Dean, Distributed representations of words and phrases and their compositionality, NIPS, 2013.

Dokümanları sıralarken Word embeddings kullanımı

Geleneksel IR sistemler **Term matching** kullanır,
→ # of times the doc says Albuquerque

Word embedding ler ise
→ # of terms in the doc that relate to Albuquerque

Albuquerque is the most populous city in the U.S. state of New Mexico. The high-altitude city serves as the county seat of Bernalillo County, and it is situated in the central part of the state, straddling the Rio Grande. The city population is 557,169 as of the July 1, 2014, population estimate from the United States Census Bureau, and ranks as the 32nd-largest city in the U.S. The Metropolitan Statistical Area (or MSA) has a population of 902,797 according to the United States Census Bureau's most recently available estimate for July 1, 2013.

Passage *about* Albuquerque

Allen suggested that they could program a BASIC interpreter for the device; after a call from Gates claiming to have a working interpreter, MITS requested a demonstration. Since they didn't actually have one, Allen worked on a simulator for the Altair while Gates developed the interpreter. Although they developed the interpreter on a simulator and not the actual device, the interpreter worked flawlessly when they demonstrated the interpreter to MITS in Albuquerque, New Mexico in March 1975; MITS agreed to distribute it, marketing it as Altair BASIC.

Passage *not about* Albuquerque

Sözlükte bulunan her kelimenin vektörlerinin saklandığı yapıya Vektör Matrisi (**Embedding Matrix**) denir

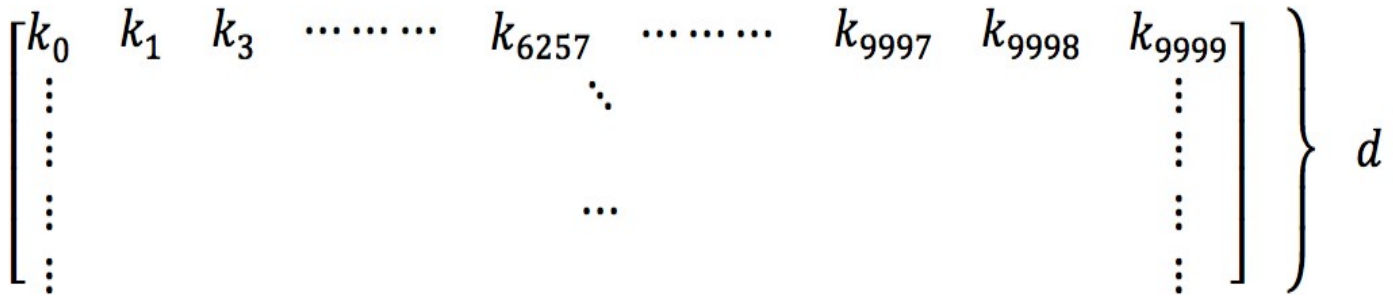

d: Vektör Boyutu

Vektör Matrislerinde:

- Bütün kelimelerin vektörleri bulunur.
- Her kelime vektörü bir sütunda yer alır.
- Kelime vektörünün boyutu **d** dir
- Sözlükte bulunan kelime sayısı **m** ise
- Vektör Matrisi boyutu **(d x m)** dir

Kelime vektörleri için kullanılan yöntemlerden en bilinenleri :
Word2Vec [1] ve GloVe [2]

GloVe, Word2Vec yönteminin üzerine bazı performans geliştirmeleri yapılmış halidir.

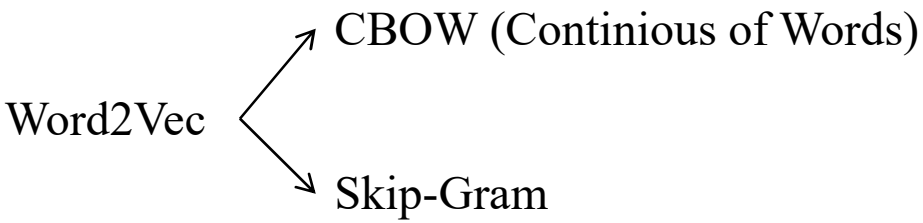

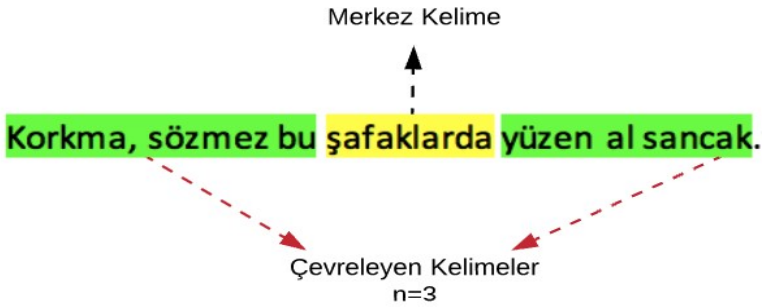

Çerçeve Boyutu (Window Size)

- Word2Vec için hiperparametrelerden biridir
- Analiz edilen kelimenin sağında ve solundaki **n** kelimeyi belirlemek için kullanılır
- Çerçeve merkezindeki kelimeye **Merkez Kelime**
- Bu kelimeye **n** yakınlıktaki kelimelere **Çevreleyen Kelimeler** denir

[1] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.

[2] Pennington, J., Socher, R., & Manning, C. (2014). Glove: Global vectors for word representation. In Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP) (pp. 1532-1543).

Word2Vec

- Birer adet girdi, çıktı ve gizli katmandan oluşan bir yapay sinir ağıdır.
- Kelime vektörlerini oluştururken pencere genişliği, embedding boyutu gibi hiper parametreleri kullanır.
- Pencere genişliği hedef kelimenin sağında ve solunda kaç kelime olması gerektiğini belirtir.
- Embedding boyutu ise her bir kelimenin kaç boyutlu vektör olarak tanımlanacağını belirtir.
- Embedding boyutu aynı zamanda gizli katmandaki nöron sayısına karşılık gelir.
- İki kelimenin birbirine olan benzerliğini veya iki cümlenin birbirine olan yakınlığını bulmak, özetlemede yararlanmak gibi birçok kullanım alanı vardır.

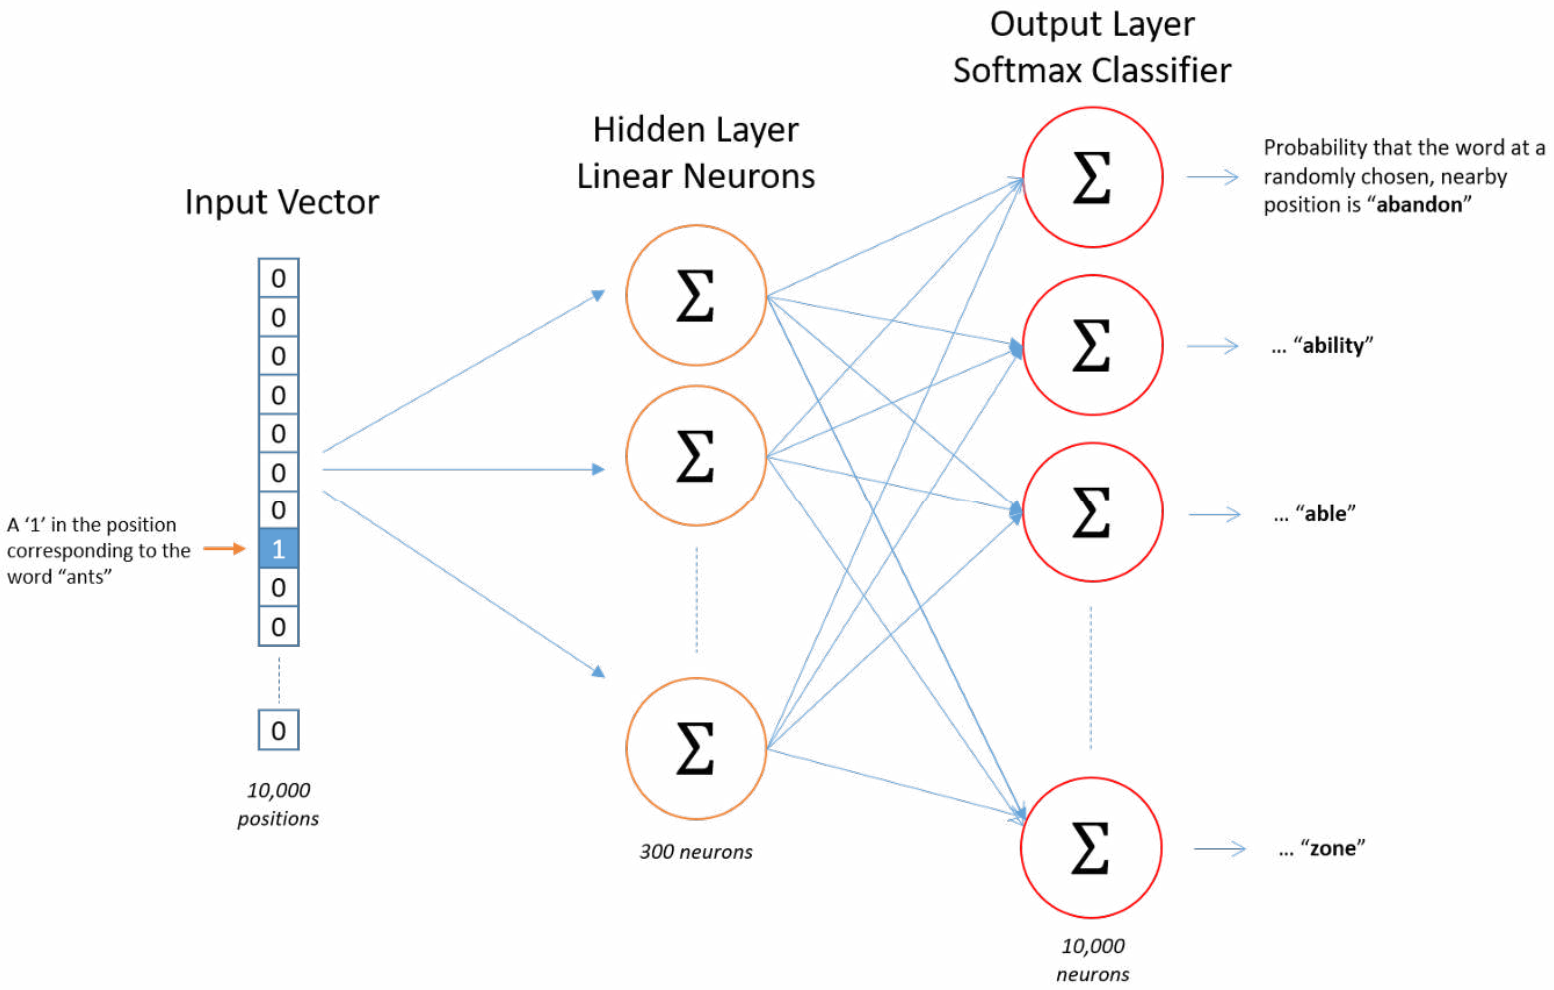
Output Layer
Softmax Classifier
Hidden Layer
Linear Neurons
Input Vector
Probability that the word at a randomly chosen, nearby position is "abandon"
... "ability"
... "able"
... "zone"
A '1' in the position corresponding to the word "ants"
0
0
0
0
0
0
0
1
0
0
0
10,000 positions
300 neurons
10,000 neurons

Skip-gram

- Girdi hedef kelime iken, çıktılar hedef kelimenin etrafındaki kelimelerdir.

- Girdiler ile çıktıları olasılıksal olarak birbirine benzeterek anlamsal olarak en uygun şekilde temsil etmek hedeflenir.

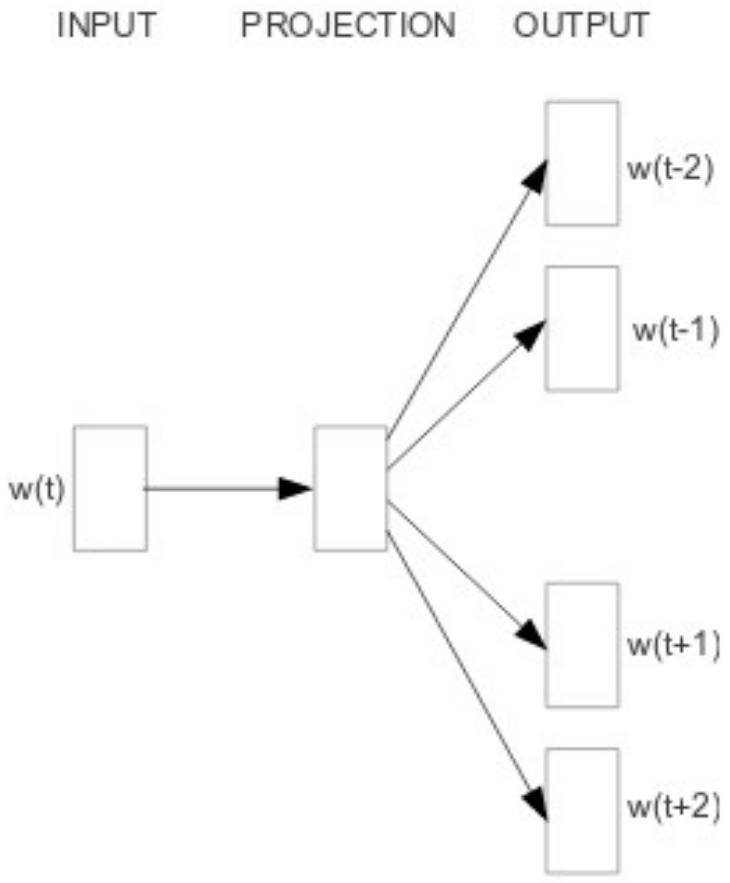

Skip-gram

Örnek: “Korkma sönmez bu şafaklarda yüzen al sancak“

cümlesi için ‘şafaklarda’ kelimesi girdi iken ve pencere boyutu 7 alındığında ‘korkma’, ‘sönmez’, ‘bu’, ‘yüzen’, ‘al’ ve ‘sancak’ kelimeleri de çıktı olarak verilir.

CBOW –
(Continuous Bag of Words)

- Buradaki fikir bir kelimenin etrafındaki kelimeler verildiğinde hangi kelimenin bu kelimeler içinde görülme olasılığının en yüksek olduğunu bilmek istemesidir.

Örnek : “Korkma sönmez bu şafaklarda yüzen al sancak“

‘korkma’, ‘sönmez’, ‘bu’, ‘yüzen’, ‘al’ ve ‘sancak’ kelimeleri girdi olarak verilirken, bu kelimelerin arasına hangi kelime gelirse daha iyi olur bulunmak istenir.

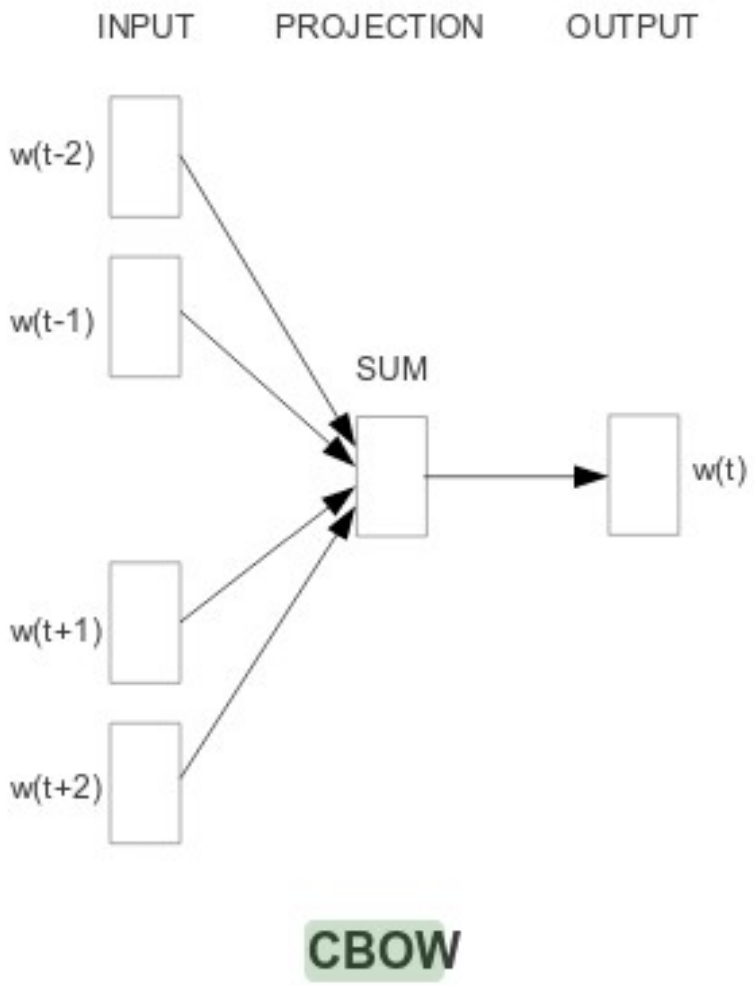

Daha detaylandırarak verecek olursak:

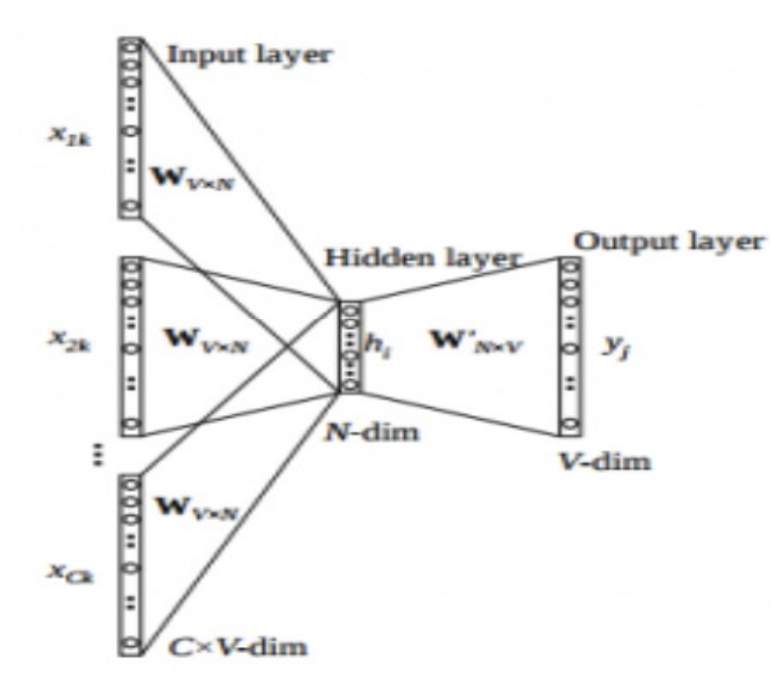

a) CBOW Ağ Yapısı

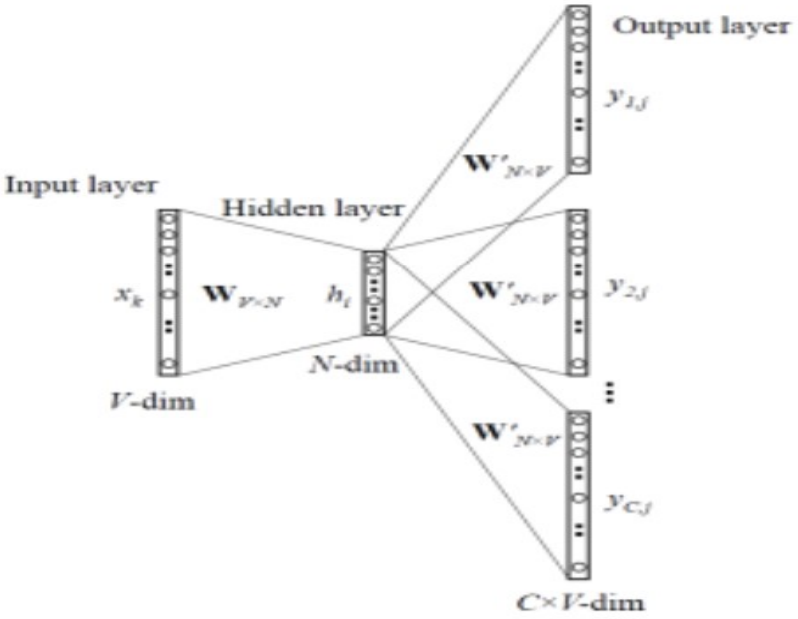

b) Skip-Gram Ağ Yapısı

- CBOW modelleri küçük veri setlerinde daha iyi sonuçlar verir
- Büyük veri setlerinde Skip-gram modeli daha iyi çalışır
- CBOW modeli için daha az işlem gücü gerekir
- Skip-gram modeli daha fazla işlem gücü tüketir
- CBOW modeli iki veya daha çok anlamlı kelimeleri anlamakta başarılı değildir
- Skip-gram iki veya daha çok anlamlı kelimeleri daha iyi öğrenir

FastText

- 2016 yılında Facebook tarafından geliştirilmiş.
- Word2Vec'in bir uzantısıdır.

- Kelimeler yapay sinir ağına girdi olarak verilmez.
- Kelimeler karakter "n-gram" lar halinde parçalanarak verilir.

Örnek *doğal* sözcüğü için **tri gram** değeri *doğ*, *oğa*, *ğal*'dır.

- N-gram ifadesindeki n (3) değeri, kelimenin kaçar kaçar bölüneceğini söyler.

- *doğal*'ın kelime vektörü tüm n-gram vektörlerinin toplamıdır.

- Eğitimin sonunda, eğitim setinde verilen tüm n-gramlar için kelime vektörleri oluşturulmuş olur.

- Az sıkılıkta geçen kelimelerin n-gramlarının ortaya çıkma olasılığı düşük olduğu için, bu kelimeler daha doğru bir şekilde temsil edilebilir.

- Bazı kelimeler eğitim veri setinde olmamasına rağmen n-gramlar sayesinde vektör değerleri hesaplanır.

- N-gram sayısı kelime sayısından çok fazla olacağı için eğitim süresi de uzar.

- Dokümanlarda az sayıda bulunan kelimeler Word2Vec'e göre daha iyi bir şekilde ifade edilir.

GloVe

- Skip-gram, CBOW gibi modeller anlamsal bilgileri yakalar ancak birlikte kullanılma istatistiklerini kullanmazlar.

- Matris ayrıştırma yöntemleri de istatistik bilgisini kullanmasına rağmen anlamsal ilişkileri yakalayamazlar.

- Pennington ve ark. tarafından önerilen “GloVe” modeli, olasılık istatistiklerinden yararlanarak yeni bir objektif fonksiyon oluşturup, bu problemi çözmeyi amaçlar.

- GloVe modelinde güncellenen hata fonksiyonu kullanılır

$$J(\theta) = \frac{1}{2} \sum_{i,j=1}^{W} f(P_{ij})(u_i^T v_j - \log P_{ij})^2$$

- GloVe modeli temel olarak hata fonksiyonunun (J) modellenmesi sırasında kelimelerin olasılık oranlarını da kullanır.

- Kelimelerin birlikte kullanım oranları ile güncellenen hata fonksiyonu ile CBOW ve Skip-Gram daki gibi çerçeve gezdirerek çevreleyen kelimelerin belirlenmesi işlemi ortadan kaldırılmıştır.

- Pij ile birlikte bulunma olasılığı yüksek kelimeler birbirlerine yakın geçtilerse bu kelimeler öğrenme işleminde diğer kelimelerden daha önemli rol oynar.

Ülke → Başkent İlişkisi

```
1 word_vectors.most_similar(positive=["londra","iran"],negative=["ingiltere"])
```

```
[('tahran', 0.6414337754249573),
 ('bağdat', 0.5921595096588135),
 ('ırak', 0.5417447090148926),
 ('kahire', 0.5351825952529907),
 ('erbil', 0.5221700072288513),
 ('suriye', 0.5216017365455627),
 ('washington', 0.5198656320571899),
 ('başkenti', 0.5075976252555847),
 ('arap', 0.4841397702693939),
 ('york', 0.47895127534866333)]
```

- ❖ Kelime vektörlerinin öğrenilmesi maliyetli bir işlemdir.
- ❖ Kelime vektörlerinin başarılı bir şekilde öğrenilebilmesi için çok büyük corpuslar üzerinde öğrenme işleminin yapılması gerekmektedir.

- ➢ Wikipedia 2014 + Gigaword 5: 6 Milyar token, tekil kelime sayısı 400.000, öğrenilen kelime vektörleri 50, 100, 200 ve 300 boyutlu

- ➢ Common Crawl 1: Dünya genelinde web sayfaları crawl edilmiş, 42 milyar token, elde edilen tekil kelime sayısı 1,9 milyon, öğrenilen kelime vektörleri 300 boyutlu

- ➢ Common Crawl 2: Dünya genelinde web sayfaları crawl edilmiş, 840 milyar token, tekil kelime sayısı 2,2 milyon, öğrenilen kelime vektörleri 300 boyutlu

- ➢ Twitter: 2 milyar tweet'ten elde edilen 27 milyar token, tekil kelime sayısı 1,2 milyon, öğrenilen kelime vektörleri 25, 50, 100 ve 200 boyutlu

Google, Google News, 100 milyar token, tekil kelime sayısı ise 3 milyon, öğrenilen vektör boyutu 300 [3]

Facebook, 294 dil için, 300 boyutlu kelime vektörleri [4]

Türkçe diline özel olarak eğitilmiş kelime vektörleri [5]

[3] Google's trained Word2Vec model in Python, http://mccormickml.com/2016/04/12/googles-pretrained-word2vec-model-in-python/

[4] Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T. (2016). Enriching word vectors with subword information. arXiv preprint arXiv:1607.04606.

[5] Word Embedding based Semantic Relation Detection for Turkish Language, https://github.com/savasy/TurkishWordEmbeddings